PUBLICATION

الذكاء الاصطناعي ومعالجة اللغة العربية الطبية: نحو توثيق سريري أكثر د

AI and Arabic Medical Language Processing: Towards More Accurate Clinical Documentation

لتحديات معالجة اللغة العربية في السياق السريري — من التعقيد الصرفي إلى تعدد اللهجات، ومن التبديل اللغوي إلى المصطلحات الطبية العربية
تحليل معمق

A deep analysis of Arabic language processing challenges in clinical settings — from morphological complexity to dialect variation, code-switching, and Arabic medical terminology.

Published:	March 2026
Document ID:	INTL-2026-008
Classification:	Public
Author:	ClinixSummary Research Team

This document is provided for informational purposes only. ClinixSummary is a product of GATMEDI. The information contained herein is proprietary and confidential.

© 2026 GATMEDI. All rights reserved. | contact@clinixsummary.ai

1. الملخص التنفيذي

يعتمد على الجذور والأوزان، وتكتب من اليمين إلى اليسار، وتتميز بتعدد اللهجات التي تختلف اختلافا جوهريا عن اللغة العربية الفصحى المعاصرة. تعد اللغة العربية من أكثر اللغات تحديا لأنظمة معالجة اللغة الطبيعية. فهي لغة سامية ذات نظام صرفي معقد

باستمرار بين العربية والإنجليزية، ويستخدمون لهجاتهم المحلية مع المرضى، ويوظفون مصطلحات طبية عربية وإنجليزية ولاتينية في الجملة الواحدة. في السياق السريري، تزداد هذه التحديات تعقيدا: فالأطباء يتنقلون

1. Executive Summary

Arabic is among the most challenging languages for natural language processing systems. It is a Semitic language with a complex morphological system based on roots and patterns, written right-to-left, and characterised by a wide spectrum of dialects that differ substantially from Modern Standard Arabic (MSA).

In clinical settings, these challenges are compounded: clinicians routinely switch between Arabic and English, use local dialects with patients, and employ Arabic, English, and Latin medical terminology within a single sentence.

2. التعقيد الصرفي للغة العربية

يعني أن الكلمة الواحدة يمكن أن تأخذ عشرات الأشكال المختلفة، مما يجعل التعرف على المصطلحات الطبية أكثر تعقيدا مقارنة باللغات الأوروبية. الصرفي العربي على نظام الجذر والوزن. فمن الجذر الثلاثي ك-ت-ب تشتق كلمات مثل: كاتب، مكتوب، كتابة، مكتب، كتاب. هذا الثراء الصرفي يعتمد النظام

2. Arabic Morphological Complexity

Arabic morphology is based on a root-and-pattern system. From the triconsonantal root k-t-b (related to writing), dozens of words are derived: kaatib (writer), maktuub (written), kitaaba (writing), maktab (office), kitaab (book). This morphological richness means a single concept can take many surface forms, making medical Named Entity Recognition (NER) significantly more complex than in European languages.

Key challenges for clinical NLP include:

• Agglutination — prepositions, conjunctions, and pronouns attach to words (e.g., “wa-bi-l-dawaa” = “and with the medication” as one token).
• Diacritics — short vowels are typically omitted in written Arabic, creating ambiguity (e.g., “” can be “ilm/science”, “allama/taught”, or “alam/flag”).
• Broken plurals — Arabic plurals often change the internal structure of the word (e.g., /tabiib → /atibbaa’), unlike regular suffixation in English.

© 2026 GATMEDI. All rights reserved. | contact@clinixsummary.ai

3. اللهجات العربية في السياق السريري

اللهجة الخليجية تختلف اختلافا كبيرا عن اللهجة المصرية أو الشامية أو المغاربية، وكل منها تستخدم ألفاظا مختلفة لوصف الأعراض والأمراض. يوجد فرق جوهري بين العربية الفصحى المعاصرة واللهجات المحلية التي يستخدمها الأطباء في تواصلهم اليومي مع المرضى.

- اللهجة الخليجية — «عندي صداع وحرارة» تعني «أعاني من صداع وحمى»
- اللهجة المصرية — «بطني بتوجعني أوي» تعني «أشعر بألم شديد في البطن»
- اللهجة الشامية — «معدتي عم توجعني كتير» تعني «أعاني من ألم شديد في المعدة»
- اللهجة المغاربية — «كنحس بالصداع ف راسي» تعني «أشعر بصداع في رأسي»

3. Arabic Dialects in Clinical Settings

There is a fundamental gap between MSA and the local dialects clinicians use daily with patients. Gulf Arabic differs markedly from Egyptian, Levantine, and Maghrebi Arabic — each uses different words to describe symptoms and conditions.

• Gulf dialect — “ ” means “I have a headache and fever.”
• Egyptian dialect — “ ” means “My stomach hurts badly.”
• Levantine dialect — “ ” means “My stomach hurts a lot.”
• Maghrebi dialect — “ ” means “I feel a headache.”

ClinixSummary recognises all major Arabic dialect families and normalises patient-reported symptoms to standard medical Arabic in the clinical note.

4. أنماط التبديل اللغوي في الممارسة السريرية

بس الـ troponin مرتفع شوية». هذا النمط المختلط طبيعي تماما في البيئة السريرية العربية، لكنه يمثل تحديا كبيرا لأنظمة معالجة اللغة الطبيعية. سمة مميزة للممارسة السريرية في العالم العربي. فالطبيب قد يقول: «المريض عنده chest pain و shortness of breath، والـ ECG طبيعي، يعد التبديل اللغوي بين العربية والإنجليزية

4. Code-Switching Patterns in Clinical Practice

Arabic-English code-switching is a defining feature of clinical practice in the Arab world. A physician might say: “ chest pain shortness of breath ECG troponin .” (The patient has chest pain and shortness of breath, the ECG is normal, but the troponin is slightly elevated.)

ClinixSummary’s Arabic NLP models handle three types of code-switching:

• Inter-sentential — switching between sentences (Arabic sentence followed by English sentence).
• Intra-sentential — switching within a sentence (Arabic frame with embedded English medical terms).
• Tag-switching — inserting English terms as tags within Arabic discourse (lab values, medication names, procedure names).

© 2026 GATMEDI. All rights reserved. | contact@clinixsummary.ai

5. المصطلحات الطبية العربية

الطبية الحديثة تستخدم بالإنجليزية في الممارسة اليومية، مما يخلق ازدواجية مصطلحية يجب على أنظمة التوثيق السريري التعامل معها.
للحضارة الإسلامية. ابن سينا والرازي وابن النفيس أسسوا مصطلحات طبية عربية لا تزال مستخدمة حتى اليوم. ومع ذلك، فإن كثيرا من المصطلحات
تمتلك اللغة العربية تراثا طبيا غنيا يعود إلى العصر الذهبي

5. Arabic Medical Terminology

Arabic has a rich medical heritage dating to the Islamic Golden Age. Ibn Sina (Avicenna), al-Razi (Rhazes), and Ibn al-Nafis established Arabic medical terminology that persists today. However, many modern medical terms are used in English in daily practice, creating a terminological duality that clinical documentation systems must handle. ClinixSummary maintains a parallel Arabic-English medical terminology database covering 50,000+ clinical concepts, enabling documentation in either language from mixed-language input.

6. الأداء والخلاصة

حقق ClinixSummary نتائج متقدمة في معالجة اللغة العربية الطبية:

- دقة التعرف على المصطلحات الطبية العربية: 93%
- دقة التعامل مع التبديل اللغوي: 94%
- تغطية اللهجات: الخليجية والمصرية والشامية والمغاربية
- معدل قبول الملاحظات في بيئات ثنائية اللغة: 91%

6. Performance and Conclusion

• Arabic medical term recognition accuracy: 93%.
• Code-switching handling accuracy: 94%.
• Dialect coverage: Gulf, Egyptian, Levantine, and Maghrebi.
• Note acceptance rate in bilingual environments: 91%.

Arabic clinical NLP is not a solved problem — it is a frontier. The morphological complexity, dialect variation, diacritics omission, and pervasive code-switching make Arabic among the most demanding languages for clinical documentation AI. ClinixSummary’s investment in Arabic-specific NLP represents a commitment to serving the 400+ million Arabic speakers who deserve clinical AI built for their language.

For a technical demonstration of Arabic NLP capabilities or to discuss deployment: international@clinixsummary.ai

© 2026 GATMEDI. All rights reserved. | contact@clinixsummary.ai